




*Flujo de inferencia*


# Ciencias con datos

# Ciencias formales



## Ciencias con datos


## Ciencias formales



Todas las ciencias con datos desarrollan  
**teorías causales** para comprender el mundo

# Industrias con datos

## Hype Cycle for Artificial Intelligence, 2025



# La ventaja de las teorías causales

$$\overbrace{-\log \lim_{T \rightarrow \infty} P(\text{Datos}_T | \text{Modelo Causal})^{1/T}}^{\text{Tasa de predicción en órdenes de magnitud}}$$

$$\begin{array}{c}
\text{Tasa de predicción en} \\
\text{órdenes de magnitud} \\
\overbrace{-\log \lim_{T \rightarrow \infty} P(\text{Datos}_T | \text{Modelo Causal})^{1/T}} \\
= \\
\sum_{c,s,r} \underbrace{P(c, s, r | \text{Realidad Causal})}_{\text{Probabilidad de que se genere el dato}} \cdot \underbrace{\left( -\log P(c, s, r | \text{Modelo Causal}) \right)}_{\text{Información en órdenes de magnitud}} \\
\overbrace{\hspace{10em}} \\
\text{Entropía cruzada}
\end{array}$$

$$\begin{array}{c}
\text{Tasa de predicción en} \\
\text{órdenes de magnitud} \\
\hline
-\log \lim_{T \rightarrow \infty} P(\text{Datos}_T | \text{Modelo Causal})^{1/T} \\
= \\
\sum_{c,s,r} \underbrace{P(c, s, r | \text{Realidad Causal})}_{\text{Probabilidad de que se genere el dato}} \cdot \underbrace{(-\log P(c, s, r | \text{Modelo Causal}))}_{\text{Información en órdenes de magnitud}} \\
\hline
\text{Entropía cruzada}
\end{array}$$

**No hay mejor predicción que la del modelo causal**  
que se corresponde con la realidad causal subyacente

Flujo de inferencia  
en redes causales


**Belief propagation**



# Flujo de inferencia

sum-product algorithm


Algoritmo para calcular cualquier marginal  
mediante pasaje de mensajes entre nodos



# Flujo de inferencia

sum-product algorithm

Algoritmo para calcular cualquier marginal  
mediante pasaje de mensajes entre nodos




$m_{x \rightarrow f}(x)$  : Mensaje de variable  $x$  a factor  $f$

$m_{f \rightarrow x}(x)$  : Mensaje de factor  $f$  a variable  $x$

# Flujo de inferencia

sum-product algorithm

Algoritmo para calcular cualquier marginal  
mediante pasaje de mensajes entre nodos



$v(n)$  : Vecinos del nodo  $n$

$m_{x \rightarrow f}(x)$  : Mensaje de variable  $x$  a factor  $f$

$m_{f \rightarrow x}(x)$  : Mensaje de factor  $f$  a variable  $x$

# Flujo de inferencia


## sum-product algorithm

$$P(x) = \prod_{f \in v(x)} m_{f \rightarrow x}(x)$$

$v(n)$  : Vecinos del nodo  $n$


$m_{x \rightarrow f}(x)$  : Mensaje de variable  $x$  a factor  $f$

$m_{f \rightarrow x}(x)$  : Mensaje de factor  $f$  a variable  $x$



# Flujo de inferencia

## sum-product algorithm



$$P(x) = \prod_{f \in v(x)} m_{f \rightarrow x}(x)$$

$v(n)$  : Vecinos del nodo  $n$


$m_{x \rightarrow f}(x)$  : Mensaje de variable  $x$  a factor  $f$

$m_{f \rightarrow x}(x)$  : Mensaje de factor  $f$  a variable  $x$

$$m_{x \rightarrow f}(x) = \prod_{h \in v(x) \setminus \{f\}} m_{h \rightarrow x}(x)$$

# Flujo de inferencia

## sum-product algorithm



$$P(x) = \prod_{f \in v(x)} m_{f \rightarrow x}(x)$$

$v(n)$  : Vecinos del nodo  $n$


$m_{x \rightarrow f}(x)$  : Mensaje de variable  $x$  a factor  $f$

$m_{f \rightarrow x}(x)$  : Mensaje de factor  $f$  a variable  $x$

$$m_{x \rightarrow f}(x) = \prod_{h \in v(x) \setminus \{f\}} m_{h \rightarrow x}(x)$$

# Flujo de inferencia

## sum-product algorithm



$$P(x) = \prod_{f \in v(x)} m_{f \rightarrow x}(x)$$

$v(n)$  : Vecinos del nodo  $n$

$m_{x \rightarrow f}(x)$  : Mensaje de variable  $x$  a factor  $f$


$m_{f \rightarrow x}(x)$  : Mensaje de factor  $f$  a variable  $x$

$$m_{x \rightarrow f}(x) = \prod_{h \in v(x) \setminus \{f\}} m_{h \rightarrow x}(x)$$

$$m_{f \rightarrow x}(x) = f(\mathbf{h}, x) \prod_{h \in v(f) \setminus \{x\}} m_{h \rightarrow f}(h)$$

# Flujo de inferencia

## sum-product algorithm



$$P(x) = \prod_{f \in v(x)} m_{f \rightarrow x}(x)$$

$v(n)$  : Vecinos del nodo  $n$

$m_{x \rightarrow f}(x)$  : Mensaje de variable  $x$  a factor  $f$

$m_{f \rightarrow x}(x)$  : Mensaje de factor  $f$  a variable  $x$


$$m_{x \rightarrow f}(x) = \prod_{h \in v(x) \setminus \{f\}} m_{h \rightarrow x}(x)$$

$$m_{f \rightarrow x}(x) = \sum_{\mathbf{h}} \left( f(\mathbf{h}, x) \prod_{h \in v(f) \setminus \{x\}} m_{h \rightarrow f}(h) \right)$$



# Flujo de inferencia

## sum-product algorithm



$$P(x) = \prod_{f \in v(x)} m_{f \rightarrow x}(x)$$

$v(n)$  : Vecinos del nodo  $n$

$m_{x \rightarrow f}(x)$  : Mensaje de variable  $x$  a factor  $f$


$m_{f \rightarrow x}(x)$  : Mensaje de factor  $f$  a variable  $x$

$$m_{x \rightarrow f}(x) = \prod_{h \in v(x) \setminus \{f\}} m_{h \rightarrow x}(x)$$

$$m_{f \rightarrow x}(x) = \sum_{\mathbf{h}} \left( f(\mathbf{h}, x) \prod_{h \in v(f) \setminus \{x\}} m_{h \rightarrow f}(h) \right)$$

# Flujo de inferencia

## sum-product algorithm



$$P(x) = \prod_{f \in v(x)} m_{f \rightarrow x}(x)$$

$v(n)$  : Vecinos del nodo  $n$

$m_{x \rightarrow f}(x)$  : Mensaje de variable  $x$  a factor  $f$

$m_{f \rightarrow x}(x)$  : Mensaje de factor  $f$  a variable  $x$

$$m_{x \rightarrow f}(x) = \prod_{h \in v(x) \setminus \{f\}} m_{h \rightarrow x}(x)$$


$$m_{f \rightarrow x}(x) = \sum_{\mathbf{h}} \left( f(\mathbf{h}, x) \prod_{h \in v(f) \setminus \{x\}} m_{h \rightarrow f}(h) \right)$$

# Flujo de inferencia

sum-product algorithm


¿Cuál es el posterior de  $p$ ?

$$P(p | \underbrace{r_1, c_1, s_1, \dots}_{\text{Datos}})$$



# Flujo de inferencia


sum-product algorithm



$$P(p | \underbrace{r_1, c_1, s_1, \dots}_{\text{Datos}}) \propto P(p, r_1, c_1, s_1, \dots)$$

# Flujo de inferencia

## sum-product algorithm




$$P(p | \underbrace{r_1, c_1, s_1, \dots}_{\text{Datos}}) \propto P(p, r_1, c_1, s_1, \dots)$$

$$= \sum_{a_1, \dots, a_T} P(p, r_1, c_1, s_1, a_1 \dots)$$

# Flujo de inferencia

sum-product algorithm




$$P(p | \underbrace{r_1, c_1, s_1, \dots}_{\text{Datos}}) \propto P(p, r_1, c_1, s_1, \dots)$$
$$= \sum_{a_1, \dots, a_T} P(p, r_1, c_1, s_1, a_1 \dots)$$

Son  $T$  sumatorias anidadas!  
(las combinaciones crecen como  $2^T$ )



# Flujo de inferencia

## sum-product algorithm



$$m_{f_r \rightarrow r}(r) =$$


$$m_{f_p \rightarrow p}(p) =$$

$$m_{f_c \rightarrow c}(c) =$$



# Flujo de inferencia

## sum-product algorithm




$$m_{f_r \rightarrow r}(r) = P(r)$$

$$m_{f_p \rightarrow p}(p) = P(p)$$

$$m_{f_c \rightarrow c}(c) = P(c)$$

# Flujo de inferencia


## sum-product algorithm



$$m_{f_s \rightarrow a}(a) =$$

# Flujo de inferencia


## sum-product algorithm



$$m_{f_s \rightarrow a}(a) = P(r)P(c)P(s|r)^{\mathbb{I}(a=0)}P(s|r, c)^{\mathbb{I}(a=1)}$$

# Flujo de inferencia


## sum-product algorithm



$$m_{f_s \rightarrow a}(a) = P(r)P(c)P(s|r)^{\mathbb{I}(a=0)}P(s|r, c)^{\mathbb{I}(a=1)} = P(r, c, s|a)$$

# Flujo de inferencia


## sum-product algorithm



$$m_{f_a \rightarrow p}(p) =$$

# Flujo de inferencia


## sum-product algorithm



$$m_{f_a \rightarrow p}(p) = \sum_a P(r, c, s|a)P(a|p)$$

# Flujo de inferencia

## sum-product algorithm



$$m_{f_a \rightarrow p}(p) = \sum_a P(r, c, s|a)P(a|p) = P(r, c, s|p)$$





# Predecir el impacto de las acciones a partir de datos observados

$$P(Y|X)$$



# Predecir el impacto de las acciones

a partir de datos observados

$$P(Y|X)$$

$\neq$


$$P(Y|\text{do}(X))$$

# Predecir el impacto de las acciones a partir de datos observados


Observaciones  
 $P(Y|X)$

$\neq$


$P(Y|\text{do}(X))$



# Predecir el impacto de las acciones a partir de datos observados




$\neq$




# Predecir el impacto de las acciones a partir de datos observados

## Entrenamos In-sample




$\neq$




# Predecir el impacto de las acciones a partir de datos observados

**Entrenamos**  
In-sample



$\neq$


**Predecimos**  
Out-of-sample



# Predecir el impacto de las acciones a partir de datos observados

**Entrenamos**  
In-sample

Observaciones  
 $P(Y|X)$



$\neq$


**Predecimos**  
Out-of-sample

Intervenciones  
 $P(Y|\text{do}(X))$

Para predecir el impacto de las acciones  
**necesitamos eliminar el flujo no causal**

# Flujo de inferencia


## Estructuras básicas





# Flujo de inferencia


## Estructuras básicas



Pipe:  $e \rightarrow a \rightarrow l$

# Flujo de inferencia


## Estructuras básicas



Pipe:  $e \rightarrow a \rightarrow l$        $P(l) \stackrel{?}{=} P(l|e)$

# Flujo de inferencia


## Estructuras básicas



Pipe:  $e \rightarrow a \rightarrow l$        $P(l) \stackrel{?}{=} P(l|e)$        $P(l|a) \stackrel{?}{=} P(l|e, a)$

# Flujo de inferencia


## Estructuras básicas



	Intermedio no observable	Intermedio observable	
Pipe:	$e \rightarrow a \rightarrow l$	$P(l) \stackrel{?}{=} P(l e)$	$P(l a) \stackrel{?}{=} P(l e, a)$

# Flujo de inferencia


## Estructuras básicas



		Intermedio no observable	Intermedio observable
Pipe:	$e \rightarrow a \rightarrow l$	$P(l) \stackrel{?}{=} P(l e)$	$P(l a) \stackrel{?}{=} P(l e, a)$
Fork:	$a \leftarrow t \rightarrow r$		

# Flujo de inferencia


## Estructuras básicas



		Intermedio no observable	Intermedio observable
Pipe:	$e \rightarrow a \rightarrow l$	$P(l) \stackrel{?}{=} P(l e)$	$P(l a) \stackrel{?}{=} P(l e, a)$
Fork:	$a \leftarrow t \rightarrow r$	$P(r) \stackrel{?}{=} P(r a)$	$P(r t) \stackrel{?}{=} P(r t, a)$

# Flujo de inferencia


## Estructuras básicas



		Intermedio no observable	Intermedio observable
Pipe:	$e \rightarrow a \rightarrow l$	$P(l) \stackrel{?}{=} P(l e)$	$P(l a) \stackrel{?}{=} P(l e, a)$
Fork:	$a \leftarrow t \rightarrow r$	$P(r) \stackrel{?}{=} P(r a)$	$P(r t) \stackrel{?}{=} P(r t, a)$
Collider:	$e \rightarrow a \leftarrow t$		

# Flujo de inferencia

## Estructuras básicas




		Intermedio no observable	Intermedio observable
Pipe:	$e \rightarrow a \rightarrow l$	$P(l) \stackrel{?}{=} P(l e)$	$P(l a) \stackrel{?}{=} P(l e, a)$
Fork:	$a \leftarrow t \rightarrow r$	$P(r) \stackrel{?}{=} P(r a)$	$P(r t) \stackrel{?}{=} P(r t, a)$
Collider:	$e \rightarrow a \leftarrow t$	$P(t) \stackrel{?}{=} P(t e)$	$P(t a) \stackrel{?}{=} P(t e, a)$



# Flujo de inferencia


## Estructuras básicas



		Intermedio no observable	Intermedio observable
Pipe:	$e \rightarrow a \rightarrow l$	$P(l) \stackrel{?}{=} P(l e)$	$P(l a) \stackrel{?}{=} P(l e, a)$
Fork:	$a \leftarrow t \rightarrow r$	$P(r) \stackrel{?}{=} P(r a)$	$P(r t) \stackrel{?}{=} P(r t, a)$
Collider:	$e \rightarrow a \leftarrow t$ $\downarrow$ $l$	$P(t) \stackrel{?}{=} P(t e)$	$P(t a) \stackrel{?}{=} P(t e, a)$ $P(t l) \stackrel{?}{=} P(t e, l)$

# Flujo de inferencia


## Estructuras básicas



		Intermedio no observable	Intermedio observable
<b>Pipe:</b>	$e \rightarrow a \rightarrow l$	$P(l) \stackrel{?}{=} P(l e)$	$P(l a) \stackrel{?}{=} P(l e, a)$
<b>Fork:</b>	$a \leftarrow t \rightarrow r$	$P(r) \stackrel{?}{=} P(r a)$	$P(r t) \stackrel{?}{=} P(r t, a)$
<b>Collider:</b>	$e \rightarrow a \leftarrow t$ $\downarrow$ $l$	$P(t) \stackrel{?}{=} P(t e)$	$P(t a) \stackrel{?}{=} P(t e, a)$ $P(t l) \stackrel{?}{=} P(t e, l)$

# Flujo de inferencia


Pipe



# Flujo de inferencia


## Pipe

$$x \longrightarrow z \longrightarrow y$$




# Flujo de inferencia

## Pipe





$$X \not\perp Y | \emptyset$$




# Flujo de inferencia

## Pipe



# Flujo de inferencia Pipe




$$P(x, y|z) =$$

$$X \perp\!\!\!\perp Y|Z$$

# Flujo de inferencia

## Pipe




$$P(x, y|z) = \frac{P(x, y, z)}{P(z)}$$

$$X \perp\!\!\!\perp Y|Z$$



# Flujo de inferencia

## Pipe




$$P(x, y|z) = \frac{P(x)P(z|x)P(y|z)}{P(z)}$$

$$X \perp\!\!\!\perp Y|Z$$

# Flujo de inferencia

## Pipe




$$P(x, y|z) = \frac{P(x)P(z|x)P(y|z)}{P(z)} = \frac{P(x)P(z|x)}{P(z)}P(y|z)$$

$$X \perp\!\!\!\perp Y|Z$$

# Flujo de inferencia

## Pipe




$$P(x, y|z) = \frac{P(x)P(z|x)P(y|z)}{P(z)} = \frac{P(x)P(z|x)}{P(z)}P(y|z) = P(x|z)P(y|z)$$

$$X \perp\!\!\!\perp Y|Z$$

# Flujo de inferencia


## Estructuras básicas



		Intermedio no observable	Intermedio observable
<b>Pipe :</b>	$e \rightarrow a \rightarrow l$	$P(l) \stackrel{?}{=} P(l e)$	$P(l a) \stackrel{?}{=} P(l e, a)$
<b>Fork:</b>	$a \leftarrow t \rightarrow r$	$P(r) \stackrel{?}{=} P(r a)$	$P(r t) \stackrel{?}{=} P(r t, a)$
<b>Collider:</b>	$e \rightarrow a \leftarrow t$ $\downarrow$ $l$	$P(t) \stackrel{?}{=} P(t e)$	$P(t a) \stackrel{?}{=} P(t e, a)$  $P(t l) \stackrel{?}{=} P(t e, l)$

# Flujo de inferencia

## Estructuras básicas




		Intermedio no observable	Intermedio observable
<b>Pipe :</b>	$e \rightarrow a \rightarrow l$	$P(l) \neq P(l e)$	$P(l a) \stackrel{?}{=} P(l e, a)$
<b>Fork:</b>	$a \leftarrow t \rightarrow r$	$P(r) \stackrel{?}{=} P(r a)$	$P(r t) \stackrel{?}{=} P(r t, a)$
<b>Collider:</b>	$e \rightarrow a \leftarrow t$ $\downarrow$ $l$	$P(t) \stackrel{?}{=} P(t e)$	$P(t a) \stackrel{?}{=} P(t e, a)$ $P(t l) \stackrel{?}{=} P(t e, l)$

$$E \not\perp L | \emptyset$$

# Flujo de inferencia

## Estructuras básicas




		Intermedio no observable	Intermedio observable
<b>Pipe :</b>	$e \rightarrow a \rightarrow l$	$P(l) \neq P(l e)$	$P(l a) = P(l e, a)$
<b>Fork:</b>	$a \leftarrow t \rightarrow r$	$P(r) \stackrel{?}{=} P(r a)$	$P(r t) \stackrel{?}{=} P(r t, a)$
<b>Collider:</b>	$e \rightarrow a \leftarrow t$ $\downarrow$ $l$	$P(t) \stackrel{?}{=} P(t e)$	$P(t a) \stackrel{?}{=} P(t e, a)$ $P(t l) \stackrel{?}{=} P(t e, l)$

$$E \not\perp L | \emptyset$$

$$E \perp L | A$$

# Flujo de inferencia

## Estructuras básicas



		Intermedio no observable	Intermedio observable
Pipe :	$e \rightarrow a \rightarrow l$	$P(l) \neq P(l e)$	$P(l a) = P(l e, a)$
<b>Fork:</b>	$a \leftarrow t \rightarrow r$	$P(r) \stackrel{?}{=} P(r a)$	$P(r t) \stackrel{?}{=} P(r t, a)$
Collider:	$e \rightarrow a \leftarrow t$ $\downarrow$ $l$	$P(t) \stackrel{?}{=} P(t e)$	$P(t a) \stackrel{?}{=} P(t e, a)$ $P(t l) \stackrel{?}{=} P(t e, l)$

# Flujo de inferencia

Fork


$$x \longleftarrow z \longrightarrow y$$



# Flujo de inferencia


Fork

$$x \longleftarrow z \longrightarrow y$$




# Flujo de inferencia

## Fork




$$X \not\perp Y | \emptyset$$




# Flujo de inferencia

## Fork




$$X \perp\!\!\!\perp Y | Z$$



# Flujo de inferencia


## Fork



$$X \perp\!\!\!\perp Y|Z \iff P(x, y|z) = P(x|z)P(y|z)$$

# Flujo de inferencia

## Fork




$$P(x, y|z) =$$

$$X \perp\!\!\!\perp Y|Z$$

# Flujo de inferencia

## Fork




$$P(x, y|z) = \frac{P(x, y, z)}{P(z)}$$

$$X \perp\!\!\!\perp Y|Z$$

# Flujo de inferencia

## Fork




$$P(x, y|z) = \frac{P(x|z)P(y|z)P(z)}{P(z)}$$

$$X \perp\!\!\!\perp Y|Z$$

# Flujo de inferencia

## Fork




$$X \perp\!\!\!\perp Y|Z$$

$$P(x, y|z) = \frac{P(x|z)P(y|z)\cancel{P(z)}}{\cancel{P(z)}}$$



# Flujo de inferencia

## Fork




$$X \perp\!\!\!\perp Y|Z$$

$$P(x, y|z) = \frac{P(x|z)P(y|z)\cancel{P(z)}}{\cancel{P(z)}} = P(x|z)P(y|z)$$

# Flujo de inferencia


## Estructuras básicas



		Intermedio no observable	Intermedio observable
Pipe:	$e \rightarrow a \rightarrow l$	$P(l) \neq P(l e)$	$P(l a) = P(l e, a)$
<b>Fork:</b>	$a \leftarrow t \rightarrow r$	$P(r) \stackrel{?}{=} P(r a)$	$P(r t) \stackrel{?}{=} P(r t, a)$
Collider:	$e \rightarrow a \leftarrow t$ $\downarrow$ $l$	$P(t) \stackrel{?}{=} P(t e)$	$P(t a) \stackrel{?}{=} P(t e, a)$ $P(t l) \stackrel{?}{=} P(t e, l)$

# Flujo de inferencia

## Estructuras básicas




		Intermedio no observable	Intermedio observable
Pipe:	$e \rightarrow a \rightarrow l$	$P(l) \neq P(l e)$	$P(l a) = P(l e, a)$
<b>Fork:</b>	$a \leftarrow t \rightarrow r$	$P(r) \neq P(r a)$	$P(r t) \stackrel{?}{=} P(r t, a)$
Collider:	$e \rightarrow a \leftarrow t$	$P(t) \stackrel{?}{=} P(t e)$	$P(t a) \stackrel{?}{=} P(t e, a)$
	$\downarrow$ $l$		$P(t l) \stackrel{?}{=} P(t e, l)$

$$A \not\perp R | \emptyset$$

# Flujo de inferencia

## Estructuras básicas




		Intermedio no observable	Intermedio observable
Pipe:	$e \rightarrow a \rightarrow l$	$P(l) \neq P(l e)$	$P(l a) = P(l e, a)$
<b>Fork:</b>	$a \leftarrow t \rightarrow r$	$P(r) \neq P(r a)$	$P(r t) = P(r t, a)$
Collider:	$e \rightarrow a \leftarrow t$ $\downarrow$ $l$	$P(t) \stackrel{?}{=} P(t e)$	$P(t a) \stackrel{?}{=} P(t e, a)$ $P(t l) \stackrel{?}{=} P(t e, l)$

$$A \not\perp\!\!\!\perp R|\emptyset$$

$$A \perp\!\!\!\perp R|T$$

# Flujo de inferencia

## Estructuras básicas



		Intermedio no observable	Intermedio observable
Pipe:	$e \rightarrow a \rightarrow l$	$P(l) \neq P(l e)$	$P(l a) = P(l e, a)$
Fork:	$a \leftarrow t \rightarrow r$	$P(r) \neq P(r a)$	$P(r t) = P(r t, a)$
Collider:	$e \rightarrow a \leftarrow t$	$P(t) \stackrel{?}{=} P(t e)$	$P(t a) \stackrel{?}{=} P(t e, a)$
	$\downarrow$ $l$		$P(t l) \stackrel{?}{=} P(t e, l)$

# Flujo de inferencia


## Collider



# Flujo de inferencia


## Collider

$$x \longrightarrow z \longleftarrow y$$




# Flujo de inferencia

## Collider




$$X \perp\!\!\!\perp Y | \emptyset$$






# Flujo de inferencia

## Collider




$$X \not\perp\!\!\!\perp Y|Z$$



# Flujo de inferencia

## Collider




$$P(x, y) =$$

$$X \perp\!\!\!\perp Y | \emptyset$$

# Flujo de inferencia

## Collider




$$P(x, y) = \sum_z P(x, y, z)$$

$$X \perp\!\!\!\perp Y | \emptyset$$

# Flujo de inferencia

## Collider




$$P(x, y) = \sum_z P(x)P(y)P(z|x, y)$$

$$X \perp\!\!\!\perp Y | \emptyset$$

# Flujo de inferencia

## Collider




$$P(x, y) = \sum_z P(x)P(y)P(z|x, y) = P(x)P(y) \sum_z P(z|x, y)$$

$$X \perp\!\!\!\perp Y | \emptyset$$

# Flujo de inferencia

## Collider




$$P(x, y) = \sum_z P(x)P(y)P(z|x, y) = P(x)P(y) \cancel{\sum_z P(z|x, y)}$$

$$X \perp\!\!\!\perp Y | \emptyset$$

# Flujo de inferencia

## Collider




$$P(x, y) = \sum_z P(x)P(y)P(z|x, y) = P(x)P(y)$$

$$X \perp\!\!\!\perp Y | \emptyset$$

# Flujo de inferencia

## Estructuras básicas




		Intermedio no observable	Intermedio observable
Pipe:	$e \rightarrow a \rightarrow l$	$P(l) \neq P(l e)$	$P(l a) = P(l e, a)$
Fork:	$a \leftarrow t \rightarrow r$	$P(r) \neq P(r a)$	$P(r t) = P(r t, a)$
Collider:	$e \rightarrow a \leftarrow t$	$P(t) \stackrel{?}{=} P(t e)$	$P(t a) \stackrel{?}{=} P(t e, a)$
	$\downarrow$ $\bar{l}$		$P(t l) \stackrel{?}{=} P(t e, l)$



# Flujo de inferencia

## Estructuras básicas




		Intermedio no observable	Intermedio observable
Pipe:	$e \rightarrow a \rightarrow l$	$P(l) \neq P(l e)$	$P(l a) = P(l e, a)$
Fork:	$a \leftarrow t \rightarrow r$	$P(r) \neq P(r a)$	$P(r t) = P(r t, a)$
Collider:	$e \rightarrow a \leftarrow t$	$P(t) = P(t e)$	$P(t a) \stackrel{?}{=} P(t e, a)$
	$\downarrow$ $\bar{l}$		$P(t l) \stackrel{?}{=} P(t e, l)$

$$T \perp\!\!\!\perp E | \emptyset$$

# Flujo de inferencia

## Estructuras básicas




		Intermedio no observable	Intermedio observable
Pipe:	$e \rightarrow a \rightarrow l$	$P(l) \neq P(l e)$	$P(l a) = P(l e, a)$
Fork:	$a \leftarrow t \rightarrow r$	$P(r) \neq P(r a)$	$P(r t) = P(r t, a)$
Collider:	$e \rightarrow a \leftarrow t$	$P(t) = P(t e)$	$P(t a) \neq P(t e, a)$
	$\downarrow$ $\bar{l}$		$P(t l) \stackrel{?}{=} P(t e, l)$

$$T \perp\!\!\!\perp E | \emptyset$$

$$T \not\perp\!\!\!\perp E | A$$

# Flujo de inferencia

## Estructuras básicas



		Intermedio no observable	Intermedio observable
Pipe:	$e \rightarrow a \rightarrow l$	$P(l) \neq P(l e)$	$P(l a) = P(l e, a)$
Fork:	$a \leftarrow t \rightarrow r$	$P(r) \neq P(r a)$	$P(r t) = P(r t, a)$
Collider:	$e \rightarrow a \leftarrow t$	$P(t) = P(t e)$	$P(t a) \neq P(t e, a)$
	$\downarrow$ $l$		$P(t l) \neq P(t e, l)$

$$T \perp\!\!\!\perp E | \emptyset$$

$$T \not\perp\!\!\!\perp E | L$$

# Flujo de inferencia

## Estructuras complejas (caminos)

Hay flujo de inferencia entre los extremos de una cadena si:  
(camino *d-conectado*)

- Todas las consecuencias comunes (o sus descendientes) son observables
- Ninguna otra variable es observable

# Flujo de inferencia

## Estructuras complejas (caminos)


Hay flujo de inferencia entre los extremos de una cadena si:  
(camino *d-conectado*)

- Todas las consecuencias comunes (o sus descendientes) son observables
- Ninguna otra variable es observable

Se cierra el flujo si está no *d-conectado*  
d-separado


# Flujo de inferencia

## Estructuras complejas (caminos)





# Flujo de inferencia

## Estructuras complejas (caminos)



# Flujo de inferencia



## Estructuras complejas (caminos)







# Flujo de inferencia

## Estructuras complejas (caminos)



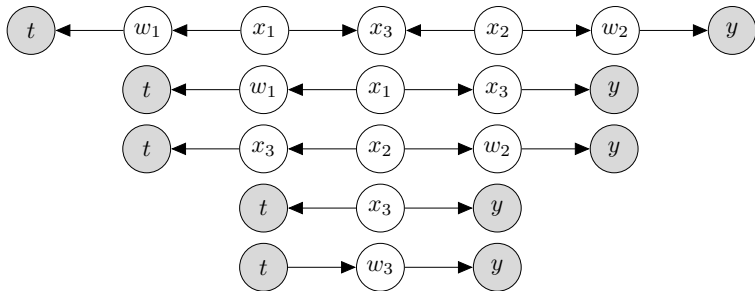

# Flujo de inferencia

## Estructuras complejas (caminos)



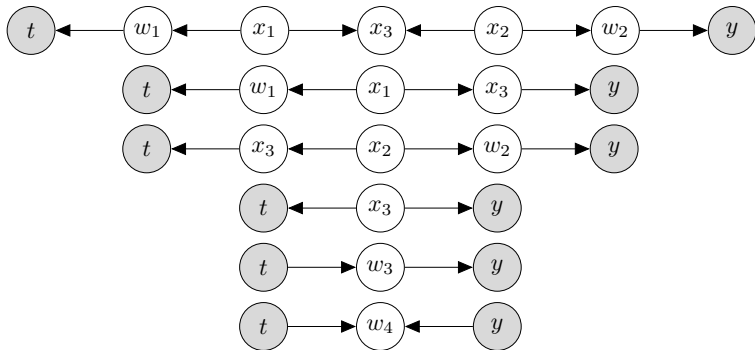

# Flujo de inferencia

## Estructuras complejas (caminos)



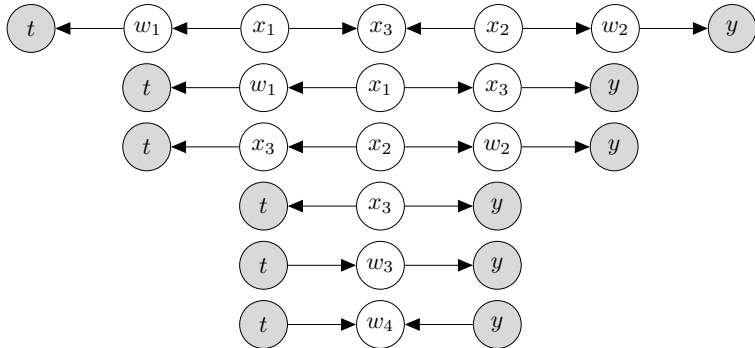

# Flujo de inferencia

## Estructuras complejas (caminos)



# Flujo de inferencia

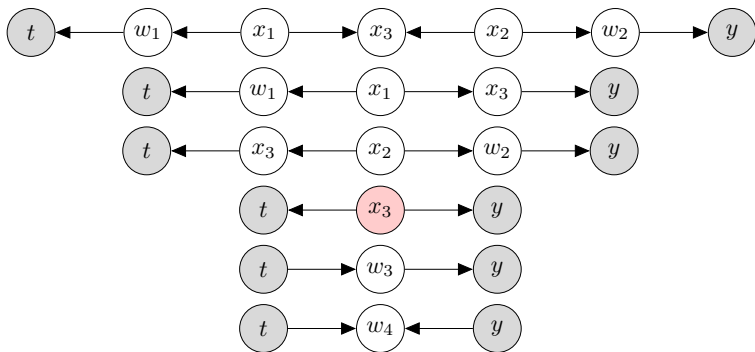

## Estructuras complejas (caminos)



Para hacer predicciones “causales” necesitamos eliminar el flujo de inferencia que circula por los caminos no causales

# Flujo de inferencia

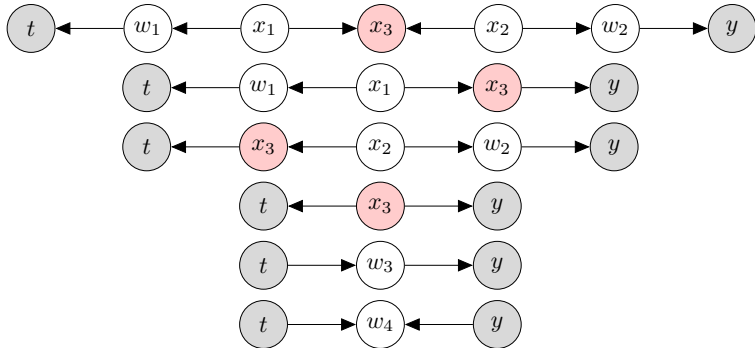

## Estructuras complejas (caminos)



Para hacer predicciones “causales” necesitamos eliminar el flujo de inferencia que circula por los caminos no causales

# Flujo de inferencia

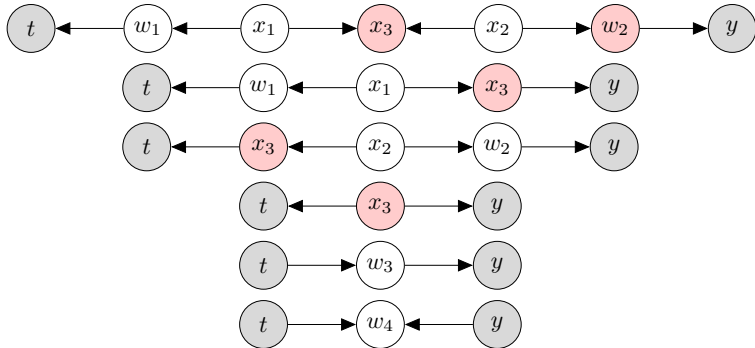

## Estructuras complejas (caminos)



Para hacer predicciones “causales” necesitamos eliminar el flujo de inferencia que circula por los caminos no causales

# Flujo de inferencia

## Estructuras complejas (caminos)



Para hacer predicciones “causales” necesitamos eliminar el flujo de inferencia que circula por los caminos no causales



# Flujo de inferencia


## Variables de control

### Backdoor criterion


Dado un conjunto de variable  $Q$  tal que:

1.  $Q$  cierra todos los caminos traseros de  $T$  a  $Y$
2.  $Q$  no contiene ningún descendiente de  $T$


# Controles buenos




# Controles buenos




# Controles buenos




# Controles buenos




# Controles buenos



# Controles buenos




# Controles malos






# Controles malos



# Controles malos

## Sesgo de selección




# Controles malos

## Sesgo de selección

Caso borde  $Y = Z$ .

$$\mathbb{E}[Y|T, Z] = \mathbb{E}[Y|T, Y]$$




# Controles malos

## Sesgo de selección

Caso borde  $Y = Z$ .  $T$  se hace independiente de  $Y$ .

$$\mathbb{E}[Y|T, Z] = \mathbb{E}[Y|T, Y] = \mathbb{E}[Y|Y] = Y$$




# Controles malos


## Sesgo de selección

Caso borde  $M = Z$ .  $T$  se hace independiente de  $Y$ .


$$\mathbb{E}[Y|T, Z] = \mathbb{E}[Y|T, M]$$



# Controles malos




# Controles malos



# Controles neutrales


Mejoran precisión





# Controles neutrales

Mejoran precisión




## Efectos causales heterogéneos

Distintos en función de las características de las personas

# Controles neutrales

Mejoran precisión




## Efectos causales heterogéneos


Distintos en función de las características de las personas

# Controles

Reducen precisión




# Controles malos




Para predecir el impacto de las acciones  
necesitamos conocer la estructura causal subyacente

Los modelos causales son buenos para  
predecir porque se adaptan al contexto

Para predecir el impacto de las acciones  
necesitamos conocer la estructura causal subyacente




Para predecir el impacto de las acciones  
necesitamos conocer la estructura causal subyacente



En los experimentos *aleatorizados* (y en las intervenciones determinísticas)  
el tratamiento se asigna independientemente de sus causas naturales.

Para predecir el impacto de las acciones  
necesitamos conocer la estructura causal subyacente




$\text{do}(X_i)$

La intervención modifica el mecanismo causal de  $X$ :  $P(\text{do}(X_i = x)) = \mathbb{I}(X_i = x)$




Para predecir el impacto de las acciones  
necesitamos conocer la estructura causal subyacente



$$\underbrace{P(y_i | \text{do}(x_i), M)}_{\text{El impacto de la intervención}} \underbrace{=}_{\text{es}} \underbrace{P(y_i | x_i, M_x)}_{\text{la distribución condicional en el modelo intervenido}}$$


Para predecir el impacto de las acciones  
necesitamos conocer la estructura causal subyacente



$$P(y_i | \text{do}(x_i)) = P_{M_x}(y_i | x_i)$$

otra notación común


Para predecir el impacto de las acciones  
necesitamos conocer la estructura causal subyacente



$$P(y_i|\text{do}(x_i)) = P_{M_x}(y_i|x_i)$$

el operador  $\text{do}()$  modifica la realidad causal subyacente

Para predecir el impacto de las acciones  
necesitamos conocer la estructura causal subyacente



$$P(y_i | \text{do}(x_i)) = P_{M_x}(y_i | x_i)$$

en el modelo intervenido toda la asociación es causal (no hay asociación espuria)

¿Cómo **predecir** el **impacto causal**  
a partir de **datos observados sin intervenciones**?

# Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial:  $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento:  $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final:  $E_1 \in \{\text{Leve (0), Severo (1)}\}$

# Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial:  $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento:  $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final:  $E_1 \in \{\text{Leve (0), Severo (1)}\}$

¿El Tratamiento es efectivo para mejorar el estado del paciente?

# Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial:  $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento:  $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final:  $E_1 \in \{\text{Leve (0), Severo (1)}\}$

	$E_0 = 0$	$E_0 = 1$
$T = 0$		
$T = 1$		



# Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial:  $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento:  $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final:  $E_1 \in \{\text{Leve (0), Severo (1)}\}$

	$E_0 = 0$	$E_0 = 1$
$T = 0$	$P(E_1 = 1 T = 0, E_0 = 0)$	
$T = 1$	$P(E_1 = 1 T = 1, E_0 = 0)$	

# Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial:  $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento:  $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final:  $E_1 \in \{\text{Leve (0), Severo (1)}\}$

	$E_0 = 0$	$E_0 = 1$
$T = 0$	$P(E_1 = 1 T = 0, E_0 = 0)$	
$T = 1$	$P(E_1 = 1 T = 1, E_0 = 0)$	
	$P(E_1=1 \mathbf{T=0}, E_0=0)$ $-P(E_1=1 \mathbf{T=1}, E_0=0)$	

# Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial:  $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento:  $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final:  $E_1 \in \{\text{Leve (0), Severo (1)}\}$

	$E_0 = 0$	$E_0 = 1$	
$T = 0$	$P(E_1 = 1 T = 0, E_0 = 0)$	$P(E_1 = 1 T = 0, E_0 = 1)$	
$T = 1$	$P(E_1 = 1 T = 1, E_0 = 0)$	$P(E_1 = 1 T = 1, E_0 = 1)$	
	$P(E_1=1 \mathbf{T=0}, E_0=0)$ $-P(E_1=1 \mathbf{T=1}, E_0=0)$		

# Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial:  $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento:  $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final:  $E_1 \in \{\text{Leve (0), Severo (1)}\}$

	$E_0 = 0$	$E_0 = 1$	
$T = 0$	$P(E_1 = 1 T = 0, E_0 = 0)$	$P(E_1 = 1 T = 0, E_0 = 1)$	
$T = 1$	$P(E_1 = 1 T = 1, E_0 = 0)$	$P(E_1 = 1 T = 1, E_0 = 1)$	
	$P(E_1=1 \mathbf{T=0}, E_0=0)$ $-P(E_1=1 \mathbf{T=1}, E_0=0)$	$P(E_1=1 \mathbf{T=0}, E_0=1)$ $-P(E_1=1 \mathbf{T=1}, E_0=1)$	

# Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial:  $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento:  $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final:  $E_1 \in \{\text{Leve (0), Severo (1)}\}$

	$E_0 = 0$	$E_0 = 1$	
$T = 0$	$P(E_1 = 1 T = 0, E_0 = 0)$	$P(E_1 = 1 T = 0, E_0 = 1)$	$P(E_1 = 1 T = 0)$
$T = 1$	$P(E_1 = 1 T = 1, E_0 = 0)$	$P(E_1 = 1 T = 1, E_0 = 1)$	$P(E_1 = 1 T = 1)$
	$P(E_1=1 \mathbf{T=0}, E_0=0)$ $-P(E_1=1 \mathbf{T=1}, E_0=0)$	$P(E_1=1 \mathbf{T=0}, E_0=1)$ $-P(E_1=1 \mathbf{T=1}, E_0=1)$	

# Predicción/estimación de impacto causal

con datos observados sin intervenciones

- Estado inicial:  $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento:  $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final:  $E_1 \in \{\text{Leve (0), Severo (1)}\}$

	$E_0 = 0$	$E_0 = 1$	
$T = 0$	$P(E_1 = 1 T = 0, E_0 = 0)$	$P(E_1 = 1 T = 0, E_0 = 1)$	$P(E_1 = 1 T = 0)$
$T = 1$	$P(E_1 = 1 T = 1, E_0 = 0)$	$P(E_1 = 1 T = 1, E_0 = 1)$	$P(E_1 = 1 T = 1)$
	$P(E_1=1 \mathbf{T=0}, E_0=0)$ $-P(E_1=1 \mathbf{T=1}, E_0=0)$	$P(E_1=1 \mathbf{T=0}, E_0=1)$ $-P(E_1=1 \mathbf{T=1}, E_0=1)$	$P(E_1=1 \mathbf{T=0})$ $-P(E_1=1 \mathbf{T=1})$

# Predicción/estimación de impacto causal


con datos observados sin intervenciones

- Estado inicial:  $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento:  $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final:  $E_1 \in \{\text{Leve (0), Severo (1)}\}$

	$E_0 = 0$	$E_0 = 1$	
$T = 0$	15% 210/1400	30% 30/100	16% 240/1500
$T = 1$	10% 5/50	20% 100/500	19% 105/550
	-5%	-10%	+4%

# Predicción/estimación de impacto causal


con datos observados sin intervenciones





# Predicción/estimación de impacto causal

con datos observados sin intervenciones



# Predicción/estimación de impacto causal

con datos observados sin intervenciones

Para predecir el impacto causal de las acciones  
**necesitamos conocer la estructura causal subyacente**


# Estimación de efecto causal

Modelo causal ( $M$ )

- Estado inicial:  $E_0 \in \{\text{Leve (0), Severo (1)}\}$
- Tratamiento:  $T \in \{\text{Básico (0), Especial (1)}\}$
- Estado final:  $E_1 \in \{\text{Leve (0), Severo (1)}\}$


# Estimación de efecto causal

Modelo causal ( $M$ )



# Estimación de efecto causal

Modelo causal ( $M$ )




	$E_0 = 0$	$E_0 = 1$	
$T = 0$	15% 210/1400	30% 30/100	16% 240/1500
$T = 1$	10% 5/50	20% 100/500	19% 105/550

# Estimación de efecto causal

Modelo causal ( $M$ )

$P(E_0)$

$E_0 = 0$	$E_0 = 1$
1450/2050	600/2050



	$E_0 = 0$	$E_0 = 1$	
$T = 0$	15% 210/1400	30% 30/100	16% 240/1500
$T = 1$	10% 5/50	20% 100/500	19% 105/550

# Estimación de efecto causal


Modelo causal ( $M$ )

$P(E_0)$

$E_0 = 0$	$E_0 = 1$
1450/2050	600/2050

$P(T|E_0)$

	$T = 0$	$T = 1$
$E_0 = 0$	1400/1450	50/1450
$E_0 = 1$	100/600	500/600



	$E_0 = 0$	$E_0 = 1$	
$T = 0$	15% 210/1400	30% 30/100	16% 240/1500
$T = 1$	10% 5/50	20% 100/500	19% 105/550

# Estimación de efecto causal


Modelo causal ( $M$ )

$P(E_0)$

$E_0 = 0$	$E_0 = 1$
1450/2050	600/2050

$P(T|E_0)$

	$T = 0$	$T = 1$
$E_0 = 0$	1400/1450	50/1450
$E_0 = 1$	100/600	500/600



$P(E_1|T, E_0)$

$(E_0 = 0)$	$E_1 = 0$	$E_1 = 1$
$T = 0$	0.85	<b>0.15</b>
$T = 1$	0.90	<b>0.10</b>
$(E_0 = 1)$	$E_1 = 0$	$E_1 = 1$
$T = 0$	0.70	<b>0.30</b>
$T = 1$	0.80	<b>0.20</b>

	$E_0 = 0$	$E_0 = 1$	
$T = 0$	15% 210/1400	30% 30/100	16% 240/1500
$T = 1$	10% 5/50	20% 100/500	19% 105/550



# Estimación de efecto causal


Modelo causal ( $M$ )

$P(E_0)$

$E_0 = 0$	$E_0 = 1$
1450/2050	600/2050

$P(T|E_0)$

	$T = 0$	$T = 1$
$E_0 = 0$	1400/1450	50/1450
$E_0 = 1$	100/600	500/600



$P(E_1|T, E_0)$

$(E_0 = 0)$	$E_1 = 0$	$E_1 = 1$
$T = 0$	0.85	<b>0.15</b>
$T = 1$	0.90	<b>0.10</b>
$(E_0 = 1)$	$E_1 = 0$	$E_1 = 1$
$T = 0$	0.70	<b>0.30</b>
$T = 1$	0.80	<b>0.20</b>

$P(E_1|T, E_0)$  es una predicción sin asociación espuria

un efecto causal *heterogéneo*, específico a cada estado inicial  $E_0$

# Estimación de efecto causal


Modelo causal ( $M$ )

$P(E_0)$

$E_0 = 0$	$E_0 = 1$
1450/2050	600/2050

$P(T|E_0)$

	$T = 0$	$T = 1$
$E_0 = 0$	1400/1450	50/1450
$E_0 = 1$	100/600	500/600




$P(E_1|T, E_0)$

$(E_0 = 0)$	$E_1 = 0$	$E_1 = 1$
$T = 0$	0.85	<b>0.15</b>
$T = 1$	0.90	<b>0.10</b>
$(E_0 = 1)$	$E_1 = 0$	$E_1 = 1$
$T = 0$	0.70	<b>0.30</b>
$T = 1$	0.80	<b>0.20</b>

$P(E_1|\text{do}(T))?$

# Estimación de efecto causal


Modelo causal intervenido ( $M_T$ )



# Estimación de efecto causal

Modelo causal intervenido ( $M_T$ )

$$P_{M_T}(T) = \text{Bern}(0.5)$$




# Estimación de efecto causal

Modelo causal intervenido ( $M_T$ )

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$




# Estimación de efecto causal

Modelo causal intervenido ( $M_T$ )

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$




# Estimación de efecto causal

Modelo causal intervenido ( $M_T$ )

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t)$$


# Estimación de efecto causal

Modelo causal intervenido ( $M_T$ )

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)}$$




# Estimación de efecto causal

Modelo causal intervenido ( $M_T$ )

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0, t, e_1)}{P_{M_T}(t)}$$


# Estimación de efecto causal

Modelo causal intervenido ( $M_T$ )

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) P_{M_T}(t) P_{M_T}(e_1|t, e_0)}{P_{M_T}(t)}$$


# Estimación de efecto causal

Modelo causal intervenido ( $M_T$ )

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}}$$


# Estimación de efecto causal

Modelo causal intervenido ( $M_T$ )

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$\begin{aligned} P(e_1|\text{do}(t)) &= P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}} \\ &= \sum_{e_0} P_{M_T}(e_0) P_{M_T}(e_1|t, e_0) \end{aligned}$$


# Estimación de efecto causal

Modelo causal intervenido ( $M_T$ )

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



$$\begin{aligned} P(e_1|\text{do}(t)) &= P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}} \\ &= \sum_{e_0} P(e_0) P(e_1|t, e_0) \end{aligned}$$


# Estimación de efecto causal

Modelo causal intervenido ( $M_T$ )

$$P_{M_T}(T) = \text{Bern}(0.5)$$

$$P_{M_T}(E_0) = P(E_0)$$

$$P_{M_T}(E_1|T, E_0) = P(E_1|T, E_0)$$



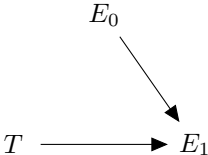
$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}}$$

$$= \underbrace{\sum_{e_0} P(e_0) P(e_1|t, e_0)}$$

Distribuciones  
observadas!

# Estimación de efecto causal

Modelo causal intervenido ( $M_T$ )

$$\begin{aligned} P_{M_T}(T) &= \text{Bern}(0.5) \\ P_{M_T}(E_0) &= P(E_0) \\ P_{M_T}(E_1|T, E_0) &= P(E_1|T, E_0) \end{aligned}$$


```
graph LR; E0 --> E1; T --> E1;
```

$$P(e_1|\text{do}(t)) = P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}}$$

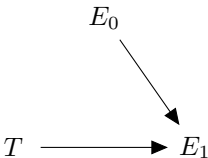
$$= \underbrace{\sum_{e_0} P(e_0) P(e_1|t, e_0)}$$

Distribuciones  
observadas!

- Encontramos los efectos causales en cada subgrupo  $P(e_1|t, e_0)$
- Y los ponderamos por el tamaño de cada subgrupo  $P(e_0)$

# Estimación de efecto causal

Modelo causal intervenido ( $M_T$ )

$$\begin{aligned} P_{M_T}(T) &= \text{Bern}(0.5) \\ P_{M_T}(E_0) &= P(E_0) \\ P_{M_T}(E_1|T, E_0) &= P(E_1|T, E_0) \end{aligned}$$


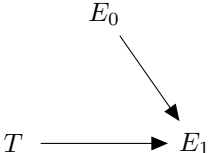
$$\begin{aligned} P(e_1|\text{do}(t)) &= P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}} \\ &= \sum_{e_0} P(e_0) P(e_1|t, e_0) \end{aligned}$$

$$\underbrace{P(E_1 = 1|\text{do}(T = 1)) - P(E_1 = 1|\text{do}(T = 0))}_{\text{Efecto causal general}}$$



# Estimación de efecto causal

Modelo causal intervenido ( $M_T$ )

$$\begin{aligned} P_{M_T}(T) &= \text{Bern}(0.5) \\ P_{M_T}(E_0) &= P(E_0) \\ P_{M_T}(E_1|T, E_0) &= P(E_1|T, E_0) \end{aligned}$$


```
graph LR; E0 --> E1; T --> E1;
```

$$\begin{aligned} P(e_1|\text{do}(t)) &= P_{M_T}(e_1|t) = \frac{P_{M_T}(e_1, t)}{P_{M_T}(t)} = \frac{\sum_{e_0} P_{M_T}(e_0) \cancel{P_{M_T}(t)} P_{M_T}(e_1|t, e_0)}{\cancel{P_{M_T}(t)}} \\ &= \sum_{e_0} P(e_0) P(e_1|t, e_0) \end{aligned}$$

$$\underbrace{P(E_1 = 1|\text{do}(T = 1)) - P(E_1 = 1|\text{do}(T = 0))}_{\text{Efecto causal general}} = -0.0646$$

# Los 4 pasos de la estimación de efecto causales

# Los 4 pasos de la estimación de efecto causales

1. Especificar la estructura causal subyacente.

# Los 4 pasos de la estimación de efecto causales

1. Especificar la estructura causal subyacente.
2. Definir el estimando (variables de control y modelo)

# Los 4 pasos de la estimación de efecto causales

1. Especificar la estructura causal subyacente.
2. Definir el estimando (variables de control y modelo)
3. Computar las estimaciones de impacto causal

# Los 4 pasos de la estimación de efecto causales

1. Especificar la estructura causal subyacente.
2. Definir el estimando (variables de control y modelo)
3. Computar las estimaciones de impacto causal
4. Validar los resultados

# Los 4 pasos de la estimación de efecto causales

1. **Especificar la estructura causal subyacente.**
2. Definir el estimando (variables de control y modelo)
3. Computar las estimaciones de impacto causal
4. Validar los resultados

# Los 4 pasos de la estimación de efecto causales


## Especificar la estructura causal subyacente

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$





# Los 4 pasos de la estimación de efecto causales

1. **Especificar la estructura causal subyacente.**
2. Definir el estimando (variables de control y modelo)
3. Computar las estimaciones de impacto causal
4. Validar los resultados

# Los 4 pasos de la estimación de efecto causales

Definir el estimando (variables de control y modelo)

1. **Especificar la estructura causal subyacente.**
2. **Definir el estimando (variables de control y modelo)**
3. Computar las estimaciones de impacto causal
4. Validar los resultados

# Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



# Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



# Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



¿Qué polinomio debemos usar para modelar la regresión lineal?

# Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



¿Qué polinomio debemos usar para modelar la regresión lineal?

Siempre podemos evaluar modelos alternativos en base a la evidencia

# Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



¿Qué polinomio debemos usar para modelar la regresión lineal?

Pero acá conocemos la función.

# Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



¿Qué polinomio debemos usar para modelar la regresión lineal?

$$\mathbb{E}[y|m] = -1 + 2m^2$$



# Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



¿Qué polinomio debemos usar para modelar la regresión lineal?

$$\mathbb{E}[y|m] = -1 + 2m^2 = -1 + 2(2z^2 + 10x)^2$$

# Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



¿Qué polinomio debemos usar para modelar la regresión lineal?

$$\begin{aligned}\mathbb{E}[y|m] &= -1 + 2m^2 = -1 + 2(2z^2 + 10x)^2 \\ &= -1 + 200x^2 + 80xz^2 + 8z^4 = \mathbb{E}[y|x, z]\end{aligned}$$

# Los 4 pasos de la estimación de efecto causales


Definir el estimando (variables de control y modelo)

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



¿Qué polinomio debemos usar para modelar la regresión lineal?

$$y \sim x^2 + xz^2 + z^4$$

# Los 4 pasos de la estimación de efecto causales

1. **Especificar la estructura causal subyacente.**
2. **Definir el estimando (variables de control y modelo)**
3. Computar las estimaciones de impacto causal
4. Validar los resultados


# Los 4 pasos de la estimación de efecto causales

## Computar las estimaciones de impacto causal

1. **Especificar la estructura causal subyacente.**
2. **Definir el estimando (variables de control y modelo)**
3. **Computar las estimaciones de impacto causal**
4. Validar los resultados


# Los 4 pasos de la estimación de efecto causales

## Computar las estimaciones de impacto causal



# Los 4 pasos de la estimación de efecto causales

## Computar las estimaciones de impacto causal



# Los 4 pasos de la estimación de efecto causales

## Validar los resultados

1. **Especificar la estructura causal subyacente.**
2. **Definir el estimando (variables de control y modelo)**
3. **Computar las estimaciones de impacto causal**
4. **Validar los resultados**



# Los 4 pasos de la estimación de efecto causales

## Validar los resultados

1. **Especificar la estructura causal subyacente.**
2. **Definir el estimando (variables de control y modelo)**
3. **Computar las estimaciones de impacto causal**
4. **Validar los resultados**

Estimamos correctamente los efectos causales heterogéneos

$$P(y|x, z)$$

# Los 4 pasos de la estimación de efecto causales

## Validar los resultados

1. **Especificar la estructura causal subyacente.**
2. **Definir el estimando (variables de control y modelo)**
3. **Computar las estimaciones de impacto causal**
4. **Validar los resultados**

Estimamos correctamente los efectos causales heterogéneos

$$P(y|x, z)$$

pero todavía no estimamos el efecto causal general

$$P(y|\text{do}(x)) = P_{M_x}(y|x)$$


# Los 4 pasos de la estimación de efecto causales

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(x|z) = \mathcal{N}(x|z^2, 1)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$




# Los 4 pasos de la estimación de efecto causales

$$P(z) = \mathcal{N}(z|0, 1)$$

$$P(\text{do}(x)) = \mathbb{I}(X = x)$$

$$P(m|x, z) = \mathcal{N}(m|2z^2 + 10x, 1)$$

$$P(y|m) = \mathcal{N}(y|-1 + 2m^2, 1)$$



$$i \quad P(y|\text{do}(x)) = P_{M_x}(y|x) \quad ?$$

# Estimador del efecto causal general

## Adjustment formula

### **Adjustment formula**

Si un conjunto de variables  $Q$  cumple con el criterio *backdoor* de  $X$  a  $Y$ , entonces el efecto causal de  $X$  en  $Y$  es estimable (identificable) a través de la siguiente fórmula:

# Estimador del efecto causal general

## Adjustment formula

### Adjustment formula

Si un conjunto de variables  $Q$  cumple con el criterio *backdoor* de  $X$  a  $Y$ , entonces el efecto causal de  $X$  en  $Y$  es estimable (identificable) a través de la siguiente fórmula:

$$P(Y = y | \text{do}(X = x)) = P_{M_x}(Y = y | X = x)$$

# Estimador del efecto causal general

## Adjustment formula

### Adjustment formula

Si un conjunto de variables  $Q$  cumple con el criterio *backdoor* de  $X$  a  $Y$ , entonces el efecto causal de  $X$  en  $Y$  es estimable (identificable) a través de la siguiente fórmula:

$$\begin{aligned}P(Y = y | \text{do}(X = x)) &= P_{M_x}(Y = y | X = x) \\ &= \sum_q P_{M_x}(Y = y, Q = q | X = x)\end{aligned}$$

# Estimador del efecto causal general

Adjustment formula

## Adjustment formula

Si un conjunto de variables  $Q$  cumple con el criterio *backdoor* de  $X$  a  $Y$ , entonces el efecto causal de  $X$  en  $Y$  es estimable (identificable) a través de la siguiente fórmula:

$$\begin{aligned}P(Y = y | \text{do}(X = x)) &= P_{M_x}(Y = y | X = x) \\&= \sum_q P_{M_x}(Y = y, Q = q | X = x) \\&= \sum_q P_{M_x}(Q = q | X = x) P_{M_x}(Y = y | X = x, Q = q)\end{aligned}$$



# Estimador del efecto causal general

Adjustment formula

## Adjustment formula

Si un conjunto de variables  $\mathbf{Q}$  cumple con el criterio *backdoor* de  $X$  a  $Y$ , entonces el efecto causal de  $X$  en  $Y$  es estimable (identificable) a través de la siguiente fórmula:

$$\begin{aligned}P(Y = y | \text{do}(X = x)) &= P_{M_x}(Y = y | X = x) \\&= \sum_q P_{M_x}(Y = y, Q = q | X = x) \\&= \sum_q P_{M_x}(Q = q | X = x) P_{M_x}(Y = y | X = x, Q = q) \\&\stackrel{*}{=} \sum_q P(Q = q) P(Y = y | X = x, Q = q)\end{aligned}$$

# Estimador del efecto causal general

Adjustment formula

## Adjustment formula

Si un conjunto de variables  $\mathbf{Q}$  cumple con el criterio *backdoor* de  $X$  a  $Y$ , entonces el efecto causal de  $X$  en  $Y$  es estimable (identificable) a través de la siguiente fórmula:

$$\begin{aligned}P(Y = y | \text{do}(X = x)) &= P_{M_x}(Y = y | X = x) \\&= \sum_q P_{M_x}(Y = y, Q = q | X = x) \\&= \sum_q P_{M_x}(Q = q | X = x) P_{M_x}(Y = y | X = x, Q = q) \\&\stackrel{*}{=} \sum_q P(Q = q) \underbrace{P(Y = y | X = x, Q = q)}_{\text{Estimación del efecto causal específico a } q}\end{aligned}$$

# Estimador del efecto causal general

## Adjustment formula

### Adjustment formula

Si un conjunto de variables  $\mathbf{Q}$  cumple con el criterio *backdoor* de  $X$  a  $Y$ , entonces el efecto causal de  $X$  en  $Y$  es estimable (identificable) a través de la siguiente fórmula:

$$\begin{aligned}P(Y = y | \text{do}(X = x)) &= P_{M_x}(Y = y | X = x) \\&= \sum_q P_{M_x}(Y = y, Q = q | X = x) \\&= \sum_q P_{M_x}(Q = q | X = x) P_{M_x}(Y = y | X = x, Q = q) \\&=^* \sum_q \underbrace{P(Q = q)}_{\text{Peso de } q} \underbrace{P(Y = y | X = x, Q = q)}_{\text{Estimación del efecto causal específico a } q}\end{aligned}$$

# Estimador del efecto causal general

Adjustment formula

## **Demostración**

# Estimador del efecto causal general

## Adjustment formula

### **Demostración**

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) \stackrel{?}{=} P(Y = y|X = x, Q = q)$

# Estimador del efecto causal general

## Adjustment formula

### **Demostración**

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) \stackrel{?}{=} P(Y = y|X = x, Q = q)$

Parte 2.  $P_{M_x}(Q = q|X = x) \stackrel{?}{=} P(Q = q)$

# Estimador del efecto causal general

## Adjustment formula

### **Demostración**

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) \stackrel{?}{=} P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.

# Estimador del efecto causal general

## Adjustment formula

### Demostración

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) \stackrel{?}{=} P(Y = y|X = x, Q = q)$

- 1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.
- 1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.



# Estimador del efecto causal general

## Adjustment formula

### **Demostración**

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

- 1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.
- 1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.

# Estimador del efecto causal general

Adjustment formula

## Demostración

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.

Parte 2.  $P_{M_x}(Q = q|X = x) \stackrel{?}{=} P(Q = q)$

# Estimador del efecto causal general

Adjustment formula

## Demostración

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.

Parte 2.  $P_{M_x}(Q = q|X = x) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo  $X$  no recibe flechas, se conecta con  $Q$  solo por caminos con collider ocultos.

# Estimador del efecto causal general

Adjustment formula

## Demostración

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.

Parte 2.  $P_{M_x}(Q = q|X = x) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo  $X$  no recibe flechas, se conecta con  $Q$  solo por caminos con collider ocultos. Luego,  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

# Estimador del efecto causal general

Adjustment formula

## Demostración

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.

Parte 2.  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo  $X$  no recibe flechas, se conecta con  $Q$  solo por caminos con collider ocultos. Luego,  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

# Estimador del efecto causal general

Adjustment formula

## Demostración

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.

Parte 2.  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo  $X$  no recibe flechas, se conecta con  $Q$  solo por caminos con collider ocultos. Luego,  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de  $X$ ).

# Estimador del efecto causal general

## Adjustment formula

### Demostración

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.

Parte 2.  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo  $X$  no recibe flechas, se conecta con  $Q$  solo por caminos con collider ocultos. Luego,  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de  $X$ ). Sea  $W$  el resto de las variables.

$$P(Q) = \sum_{W, X, Y} P(Q, W, X, Y)$$

# Estimador del efecto causal general

## Adjustment formula

### Demostración

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.

Parte 2.  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo  $X$  no recibe flechas, se conecta con  $Q$  solo por caminos con collider ocultos. Luego,  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de  $X$ ). Sea  $W$  el resto de las variables.

$$P(Q) = \sum_{W, X, Y} P(Q)P(W, X, Y|Q)$$



# Estimador del efecto causal general

## Adjustment formula

### Demostración

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.

Parte 2.  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo  $X$  no recibe flechas, se conecta con  $Q$  solo por caminos con collider ocultos. Luego,  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de  $X$ ). Sea  $W$  el resto de las variables.

$$P(Q) = P(Q) \sum_{W, X, Y} P(W, X, Y|Q)$$

# Estimador del efecto causal general

## Adjustment formula

### Demostración

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.

Parte 2.  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo  $X$  no recibe flechas, se conecta con  $Q$  solo por caminos con collider ocultos. Luego,  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de  $X$ ). Sea  $W$  el resto de las variables.

$$P(Q) = P(Q) \underbrace{\sum_{W, X, Y} P(W, X, Y|Q)}_1$$

# Estimador del efecto causal general

## Adjustment formula

### Demostración

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.

Parte 2.  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo  $X$  no recibe flechas, se conecta con  $Q$  solo por caminos con collider ocultos. Luego,  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de  $X$ ). Sea  $W$  el resto de las variables.

$$P(Q) = P(Q) \sum_{W, X, Y} P(W, Y|Q)P(X|Q, W, Y)$$

# Estimador del efecto causal general

## Adjustment formula

### Demostración

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.

Parte 2.  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo  $X$  no recibe flechas, se conecta con  $Q$  solo por caminos con collider ocultos. Luego,  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de  $X$ ). Sea  $W$  el resto de las variables.

$$P(Q) = P(Q) \sum_{W,Y} P(W,Y|Q) \sum_X P(X|Q,W,Y)$$

# Estimador del efecto causal general

## Adjustment formula

### Demostración

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.

Parte 2.  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo  $X$  no recibe flechas, se conecta con  $Q$  solo por caminos con collider ocultos. Luego,  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de  $X$ ). Sea  $W$  el resto de las variables.

$$P(Q) = P(Q) \sum_{W,Y} P(W,Y|Q) \underbrace{\sum_X P(X|Q,W,Y)}_1$$

# Estimador del efecto causal general

## Adjustment formula

### Demostración

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.

Parte 2.  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo  $X$  no recibe flechas, se conecta con  $Q$  solo por caminos con collider ocultos. Luego,  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de  $X$ ). Sea  $W$  el resto de las variables.

$$P(Q) = P(Q) \sum_{W,Y} P(W,Y|Q)$$

# Estimador del efecto causal general

## Adjustment formula

### Demostración

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.

Parte 2.  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) \stackrel{?}{=} P(Q = q)$

2.a En el lado izquierdo  $X$  no recibe flechas, se conecta con  $Q$  solo por caminos con collider ocultos. Luego,  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de  $X$ ). Sea  $W$  el resto de las variables.

$$P(Q) = P(Q) \sum_{W,Y} P(W,Y|Q) \quad \text{la condicional de } X \text{ no afecta la marginal}$$

# Estimador del efecto causal general

## Adjustment formula

### Demostración

Parte 1.  $P_{M_x}(Y = y|X = x, Q = q) = P(Y = y|X = x, Q = q)$

1.a Del lado izquierdo toda la asociación es causal porque  $X$  no recibe flechas.

1.b Del lado derecho toda la asociación es causal porque  $Q$  corta el flujo trasero.

Parte 2.  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q) = P(Q = q)$

2.a En el lado izquierdo  $X$  no recibe flechas, se conecta con  $Q$  solo por caminos con collider ocultos. Luego,  $P_{M_x}(Q = q|X = x) = P_{M_x}(Q = q)$

2.b Ambas marginales se obtienen integrando sus conjuntas respectivas (la única diferencia es la condicional de  $X$ ). Sea  $W$  el resto de las variables.

$$P(Q) = P(Q) \sum_{W,Y} P(W,Y|Q) \quad \text{la condicional de } X \text{ no afecta la marginal}$$



# Estimador del efecto causal general

## Adjustment formula

### Adjustment formula

Si un conjunto de variables  $Q$  cumple con el criterio *backdoor* de  $X$  a  $Y$ , entonces el efecto causal de  $X$  en  $Y$  es estimable (identificable) a través de la siguiente fórmula:

$$\underbrace{P(y|\text{do}(x)) = P_{M_x}(y|x)}_{\text{Realidad intervenida}} = \sum_q \underbrace{\overbrace{P(q)}^{\text{Peso del efecto}} \overbrace{P(y|x, q)}^{\text{Efecto heterogéneo}}}_{\text{Realidad sin intervenir}}$$


# Estimación de efecto causal general

## Modelo polinomial

```
def p_Y_doX(y,x):  
    res = 0  
    for z in z_grilla:  
        pz = normal(0,1).pdf(z)  
        mu_y_xz = regression(y,x,z)  
        py_xz = norm(loc=mu_y_xz, scale=sigma).pdf(y)  
        res += (pz*py_xz)*dz  
    return res
```

# Estimación de efecto causal general

## Modelo polinomial




# Casos especiales

La disputa contra la industria del tabaco

$F$  : Fumar

$C$  : Cancer

$U$  : Otras variables




# Casos especiales

La disputa contra la industria del tabaco

$F$  : Fumar

$C$  : Cancer

$U$  : Otras variables



No podemos eliminar la asociación espuria entre  $F$  y  $C$ !

# Casos especiales


La disputa contra la industria del tabaco

$F$  : Fumar

$C$  : Cancer

$U$  : Otras variables

$D$  : Depósitos en pulmones



# Casos especiales


La disputa contra la industria del tabaco

$F$  : Fumar

$C$  : Cancer

$U$  : Otras variables

$D$  : Depósitos en pulmones



# Casos especiales


La disputa contra la industria del tabaco

$F$  : Fumar

$C$  : Cancer

$U$  : Otras variables

$D$  : Depósitos en pulmones





# Casos especiales


La disputa contra la industria del tabaco

$F$  : Fumar

$C$  : Cancer

$U$  : Otras variables

$D$  : Depósitos en pulmones



# Casos especiales


La disputa contra la industria del tabaco

$F$  : Fumar

$C$  : Cancer

$U$  : Otras variables

$D$  : Depósitos en pulmones



Ajuste frontdoor.

# Casos especiales


La disputa contra la industria del tabaco

$F$  : Fumar

$C$  : Cancer

$U$  : Otras variables

$D$  : Depósitos en pulmones



Ajuste frontdoor.

$$P(c|\text{do}(f)) = \sum_d P(c|\text{do}(d))P(d|\text{do}(f))$$

# Casos especiales


La disputa contra la industria del tabaco

$F$  : Fumar

$C$  : Cancer

$U$  : Otras variables

$D$  : Depósitos en pulmones



Ajuste frontdoor.

**Condición:** hay una sola variable mediadora.

# Casos especiales


## Experimentos imperfectos

$A$  : Asignación aleatoria

$T$  : Tratamiento

$U$  : Otras variables

$Y$  : Objetivo



# Casos especiales


## Experimentos imperfectos

$A$  : Asignación aleatoria

$T$  : Tratamiento

$U$  : Otras variables

$Y$  : Objetivo



No podemos eliminar la asociación espuria entre  $T$  e  $Y$ !

# Casos especiales


## Experimentos imperfectos

$A$  : Asignación aleatoria

$T$  : Tratamiento

$U$  : Otras variables

$Y$  : Objetivo



# Casos especiales


## Experimentos imperfectos

$A$  : Asignación aleatoria

$T$  : Tratamiento

$U$  : Otras variables

$Y$  : Objetivo





# Casos especiales


## Experimentos imperfectos

$A$  : Asignación aleatoria

$T$  : Tratamiento

$U$  : Otras variables

$Y$  : Objetivo



# Casos especiales


## Experimentos imperfectos

$A$  : Asignación aleatoria

$T$  : Tratamiento

$U$  : Otras variables

$Y$  : Objetivo



# Casos especiales


## Experimentos imperfectos

$A$  : Asignación aleatoria

$T$  : Tratamiento

$U$  : Otras variables

$Y$  : Objetivo



Instrumental variable

$$\mathbb{E}[t|\text{do}(a)] = \alpha a$$

# Casos especiales


## Experimentos imperfectos

$A$  : Asignación aleatoria

$T$  : Tratamiento

$U$  : Otras variables

$Y$  : Objetivo



Instrumental variable

$$\mathbb{E}[t|\text{do}(a)] = \alpha a$$

$$\mathbb{E}[y|\text{do}(a)] = \alpha \beta a$$

# Casos especiales


## Experimentos imperfectos

$A$  : Asignación aleatoria

$T$  : Tratamiento

$U$  : Otras variables

$Y$  : Objetivo



## Instrumental variable

$$\mathbb{E}[t|\text{do}(a)] = \alpha a$$

$$\mathbb{E}[y|\text{do}(a)] = \alpha \beta a$$

$$\mathbb{E}[y|\text{do}(x)] = \mathbb{E}[y|\text{do}(a)] / \mathbb{E}[t|\text{do}(a)]$$

# Casos especiales


## Experimentos imperfectos

$A$  : Asignación aleatoria

$T$  : Tratamiento

$U$  : Otras variables

$Y$  : Objetivo



Instrumental variable


**Condición:**  $T$  es la única variable mediadora.

# El ecosistema causal de Python

DoWhy, EconML, PyTorch y más

## Causal Inference and Discovery in Python

Unlock the secrets of modern causal machine learning  
with DoWhy, EconML, PyTorch and more



ALEKSANDER MOLAK

# Resumen de inferencia causal

## Los **niveles** del razonamiento causal

1. **Asociacional:**  $P(y|x, \text{Modelo Causal})$  y  $P(\text{Modelo Causal} | x)$

Permite evaluar el efecto y el modelo causal sólo si se cumplen ciertas condiciones



# Resumen de inferencia causal

## Los **niveles** del razonamiento causal

1. **Asociacional:**  $P(y | x, \text{Modelo Causal})$  y  $P(\text{Modelo Causal} | x)$

Permite evaluar el efecto y el modelo causal sólo si se cumplen ciertas condiciones

2. **Intervencional:**  $P(y | \text{do}(x), \text{Modelo Causal})$  y  $P(\text{Modelo Causal} | y, \text{do}(x))$

Permite evaluar tanto el efecto causal y el modelo causal

# Resumen de inferencia causal

## Los **niveles** del razonamiento causal

1. **Asociacional:**  $P(y | x, \text{Modelo Causal})$  y  $P(\text{Modelo Causal} | x)$

Permite evaluar el efecto y el modelo causal sólo si se cumplen ciertas condiciones

2. **Intervencional:**  $P(y | \text{do}(x), \text{Modelo Causal})$  y  $P(\text{Modelo Causal} | y, \text{do}(x))$

Permite evaluar tanto el efecto causal y el modelo causal

3. **Contrafactual:**  $P(\overbrace{y | \text{do}(x)}^{\text{Contrafactual}}, \overbrace{y', \text{do}(x')}^{\text{Factual}}, \text{Modelo Causal})$

Permite predecir el contrafactual (dado un modelo causal completo)

# Resumen de inferencia causal

Los **niveles** del razonamiento causal


Estos niveles surgen naturalmente  
del proceso generativo de lo datos

# Monty Hall Causal

Los **niveles** del razonamiento causal

# Monty Hall Causal

## Asociación




Asociación

$$P(r, s)$$

	$r1$	$r2$	$r3$
$s1$	0	$1/6$	$1/6$
$s2$	$1/6$	0	$1/6$
$s3$	$1/6$	$1/6$	0

# Monty Hall Causal

## Intervención




## Intervención

$$P(r, s | \text{do}(c = 1))$$

	$r1$	$r2$	$r3$
$s1$	0	0	0
$s2$	$1/6$	0	$1/3$
$s3$	$1/6$	$1/3$	0

# Monty Hall Causal


## Contrafáctico



¿Que caja hubiera señalado si hubieramos elegido la caja 2,  
dado que elegimos la caja 1 y señaló la caja 2?

# Monty Hall Causal

## Contrafáctico



Factual

$$P(r|\text{do}(c = 1), s = 2)$$


$r1$	$r2$	$r3$
$1/3$	$0$	$2/3$

¿Que caja hubiera señalado si hubieramos elegido la caja 2,  
dado que elegimos la caja 1 y señaló la caja 2?



# Monty Hall Causal

Contrafáctico




Contra factual

$$P(s', r | do(c = 1), s = 2, do(c' = 2))$$

¿Que caja hubiera señalado si hubieramos elegido la caja 2,  
dado que elegimos la caja 1 y señaló la caja 2?

# Monty Hall Causal

## Contrafáctico



Contra factual

$$P(s', r | do(c = 1), s = 2, do(c' = 2))$$

	$r1$	$r2$	$r3$
$s'1$	0	0	$2/3$
$s'2$	0	0	0
$s'3$	$1/3$	0	0

¿Que caja hubiera señalado si hubieramos elegido la caja 2, dado que elegimos la caja 1 y señaló la caja 2?

# Monty Hall Causal

Los **niveles** del razonamiento causal

## Asociación

$$P(r, s)$$

	$r1$	$r2$	$r3$
$s1$	0	$1/6$	$1/6$
$s2$	$1/6$	0	$1/6$
$s3$	$1/6$	$1/6$	0

# Monty Hall Causal

Los **niveles** del razonamiento causal

## Asociación

$$P(r, s)$$

	$r1$	$r2$	$r3$
$s1$	0	1/6	1/6
$s2$	1/6	0	1/6
$s3$	1/6	1/6	0

## Intervención

$$P(r, s | \text{do}(c = 1))$$

	$r1$	$r2$	$r3$
$s1$	0	0	0
$s2$	1/6	0	1/3
$s3$	1/6	1/3	0

# Monty Hall Causal

Los **niveles** del razonamiento causal

## Asociación

$$P(r, s)$$

	$r1$	$r2$	$r3$
$s1$	0	1/6	1/6
$s2$	1/6	0	1/6
$s3$	1/6	1/6	0

## Intervención

$$P(r, s | \text{do}(c = 1))$$

	$r1$	$r2$	$r3$
$s1$	0	0	0
$s2$	1/6	0	1/3
$s3$	1/6	1/3	0

## Contra factual

$$P(s', r | \text{do}(c' = 2), \text{do}(c = 1), s = 2)$$

	$r1$	$r2$	$r3$
$s'1$	0	0	2/3
$s'2$	0	0	0
$s'3$	1/3	0	0

$p = \mathbf{b}$

Laboratorios de  
Métodos Bayesianos